西华师范大学本科毕业论文（设计）中期检查表

论文题目：：融合 RAG 与深度思考能力的本地化大模型对话系统研究

学　　院： 数学科学学院

专　　业： 人工智能

姓　　名： 张烜荣

学　　号： 202208541006

指导教师： 陈友军

时　　间： 2026.3.6

西华师范大学 教务处制

1、毕业论文（设计）进展情况概述

自课题启动以来，本人严格按照既定进度安排推进基于本地部署大语言模型的智能客服系统研发与论文撰写工作，目前已完成课题全流程核心准备、基础开发与阶段性成果落地，整体进展顺利。

在理论研究与文献梳理方面，已完成本地大模型部署、RAG 技术、智能客服、数据安全等领域文献综述撰写，系统梳理国内外研究现状，明确云服务模式痛点与本地化部署优势，完成开题报告核心论证内容。

在系统开发与环境搭建方面，已完成 Python 虚拟环境、Node.js、MySQL、Redis 等开发环境部署，成功搭建 Ollama 本地模型运行平台，完成 FAISS 向量数据库、Sentence-BERT 嵌入模型配置；实现前后端分离架构搭建，基于 FastAPI 完成后端接口框架开发，基于 Vue.js 完成前端界面基础构建。

在核心功能实现方面，已完成用户认证系统开发，实现 JWT 身份验证、注册登录接口与权限管理；完成基础对话模块、消息数据模型设计，实现 chat 基础问答接口；完成 embedding_service 与 rag_service 集成，实现文档上传、文本向量化与初步语义检索功能，完成单元测试编写与功能验证。

在论文撰写方面，已完成绪论、研究现状、可行性分析、系统架构设计、核心功能设计等主体章节写作，按照要求推进初稿撰写，整体进度符合计划节点。

2、存在的问题和解决措施

（1）存在的问题

模型本地部署资源占用较高：运行 DeepSeek R1 等推理模型时，GPU 与内存占用偏大，低配置硬件环境下响应速度变慢，并发访问时出现延迟波动。

RAG 检索精准度有待提升：文档向量化后语义匹配精度不足，部分复杂问题检索结果与用户需求匹配度低，影响问答准确性。

论文内容整合与逻辑衔接不足：技术实现章节与理论分析衔接不够紧密，性能测试、安全性分析部分数据支撑不足，表述不够规范。

并发性能与缓存优化未完全落地：Redis 缓存策略仅完成基础配置，多用户并发测试工具未完善，系统高负载稳定性未完成验证。

联网搜索接口集成不稳定：SerpAPI 调用偶现超时、返回结果格式不统一问题，时效性知识问答可靠性不足。

（2）解决措施

优化模型资源调度：实现模型动态加载与卸载机制，根据请求量自动调配资源；降低模型并行负载，采用轻量化模型兜底应答，提升响应速度与硬件兼容性。

提升 RAG 检索效果：优化文本分块策略与向量相似度计算参数，增加关键词权重

匹配规则；补充多场景测试数据，迭代微调向量模型参数，提高检索精准度。

规范论文结构与内容：按照指导意见梳理论文逻辑，强化理论与实践对应关系；补充性能对比数据、安全性测试结果，完善图表与参考文献，统一格式规范。

完善缓存与并发优化：配置多级 Redis 缓存策略，缓存高频查询与向量结果；编写并发测试脚本，模拟多用户访问，定位瓶颈并完成接口优化。

稳定联网搜索功能：增加 API 请求超时重试机制与结果清洗逻辑，统一数据格式；配置本地知识兜底策略，避免接口异常导致应答失败。

3、下阶段毕业论文（设计）撰写计划

结合当前进度与剩余任务，下阶段将以**论文定稿、系统完善、答辩准备**为核心目标，具体计划如下：

2026 年 3 月 7 日 —3 月 10 日：完成毕业论文初稿全面自查，重点修正理论逻辑、技术描述、格式规范问题；整合系统测试数据、功能截图、性能指标，补充论文实验分析与结果章节。

2026 年 3 月 11 日 —3 月 20 日：根据指导教师修改意见，对论文进行二稿、三稿修订；完善结论、参考文献、致谢、附录等内容；同步完成系统最终优化，修复遗留 Bug，确保功能稳定运行。

2026 年 3 月 21 日 —3 月 30 日：完成毕业论文终稿定稿，按照学校要求排版、打印、装订；整理答辩材料，包括开题报告、任务书、中期报告、系统演示视频、源代码、测试记录等。

2026 年 4 月：进行答辩 PPT 制作与模拟演练，熟悉论文框架、技术路线、创新点与系统功能；完成最终答辩准备，顺利参加毕业论文答辩。

4、指导教师意见

研究计划符合要求。

指导教师签字：陈友军

2026 年 3 月 6 日